



Chatbot de Preguntas y Respuestas

Erick Chaparro Quintanar

Procesamiento de Lenguaje Natural

Maestría en Inteligencia Artificial

Profesor Gaddiel Desirena López

Objetivo	2
Marco Teórico	2
PLN	2
Embeddings	2
BERT / BETO	2
BERTIN	2
DistilBERT	3
Métricas	3
Desarrollo	4
Interfaz de usuario	4
Almacenamiento	5
Modelos	5
Chat	6
Métricas	7
DistilBeERT nos arroja estas métricas:	7
BERTIN nos arroja estas métricas:	7
Pipeline	8
Paso 1 Tokenización	8
Paso 3: Softmax y selección de posiciones	10
Paso 4: Decodificación	11
Conclusiones	11

Objetivo

Construir un chatbot conversacional que responda preguntas sobre un documento de texto cargado por el usuario, integrando embeddings, tokenización y el modelo pre entrenado BETO para extraer las respuestas de los textos, la aplicación contará con una interfaz construida con Gradio para facilitar la carga de textos y la interacción con el usuario.

Marco Teórico

PLN

El procesamiento del Lenguaje Natural (PLN) es un área de la inteligencia artificial que tiene como objetivo dotar a las máquinas de la capacidad de comprender, interpretar y generar lenguaje humano de manera significativa y útil.

Embeddings

Los embeddings son representaciones numéricas de palabras, oraciones o documentos en un espacio vectorial, la propiedad fundamental de estos espacios es que palabras con significados similares tienden a estar cercanas en el espacio vectorial.

BERT / BETO

Bert(Bidireccional Encoder]Representations from Transformers) es un modelo de lenguaje pre entrenado, BETO es una adaptación de BERT pre entrenado exclusivamente con un corpus en español, para la tarea de QA BETO permite extraer el inicio y el final de la respuesta dentro de un contexto proporcionado.

BERTIN

Variante de BERT optimizada para textos largos en español, basado en la arquitectura LongFormer que permite procesar secuencias de hasta 4096 tokens.

DistilBERT

Se basa en una técnica de compresión de modelos conocida como destilación del conocimiento, se entrena un modelo grande(modelo maestro) en este caso BERT, posteriormente se entrena un modelo más pequeño llamado modelo estudiante que imita el comportamiento del modelo maestro.

Métricas


Las métricas nos permiten evaluar cuantitativamente el rendimiento de los modelos que estamos utilizando, se calculan comparando las respuestas del modelo contra las respuestas esperadas en un set de datos de prueba.

- Exact Match(EM): Mide el porcentaje de predicciones que coinciden exactamente con la respuesta esperada, si la respuesta predicha es igual a la respuesta correcta se considera un acierto.
 - Fórmula: $EM = (\text{Predicciones correctas} / \text{Total de preguntas}) * 100$
- F1 Score: Mide el equilibrio entre Precisión y Recall.
 - Formula: $F1 = 2 * (\text{Precisión} * \text{Recall}) / (\text{Precision} + \text{Recall})$
- Precisión: Mide qué proporción de los tokens en la respuesta predicha son correctos (es decir, aparecen en la respuesta esperada).
 - Fórmula: $\text{Precisión} = \text{Tokens correctos en la predicción} / \text{Total de tokens predichos}$
- Recall: Mide qué proporción de los tokens de la respuesta esperada fueron capturados por la predicción del modelo.
 - Fórmula: $\text{Recall} = \text{Tokens correctos en la predicción} / \text{Total de tokens esperados}$

Desarrollo


Interfaz de usuario

Se desarrolló una interfaz de usuario con Gradio, en el panel lateral se podrán dar de alta nuevos chats y subir los documentos txt que se utilizarán como contexto para hacer las preguntas, se podrá cambiar de chat seleccionando alguno de la lista de chats y también se podrá seleccionar el modelo que se utilizará para hacer las preguntas.



Almacenamiento


Cada uno de los archivos que se asignan a los chats se guardan en la carpeta Files, cuando se inicia el chat toma los archivos existentes en esa carpeta y crea los chats correspondientes.



Modelos

Los modelos que se utilizaron para el procesamiento de preguntas y contexto son BERTIN y DistilBERT, BERTIN se eligió porque puede procesar contextos más grandes con mayor precisión y DistilBERT aunque procesa menos contexto la velocidad de procesamiento es mayor.

Los modelos se guardan dentro de una carpeta llamada **Modelos** para evitar que cada vez que el proyecto se ejecute o al cambiar entre modelos se tenga que esperar al entrenamiento, solo cargamos los modelos ya entrenados a memoria y ya podemos utilizarlos.



Chat

Dentro del chat una vez cargado el archivo de contexto podemos empezar a hacer preguntas seleccionando el modelo a utilizar o combinando modelos, en este caso hacemos la misma pregunta a los dos modelos, podemos notar que la respuesta es diferente y el porcentaje de confianza también cambia, aunque BERTIN es un modelo más grande el porcentaje de confianza es menor, esto se debe al entrenamiento que tiene cada uno de ellos, BERTIN es más estable en su porcentaje de confianza y DistilBert cuando acierta su confianza es muy alta y cuando falla también es muy baja.

The screenshot shows a web interface for a chatbot. On the left, there's a sidebar with options: 'Nuevo chat' (New chat), 'Chats' (with 'HuggingFace' and 'MachineLearning' buttons), 'Eliminar chat' (Delete chat), 'Cargar archivo .txt' (Load .txt file), and 'Modelo' (Model) set to 'BERTIN'. The main area is titled 'Chatbot de Preguntas y Respuestas (QA)' and shows a conversation history. The first conversation, titled 'Conversacion - MachineLearning - BERTIN', shows a question '¿Qué es el Machine Learning?' and a response 'R: una rama de la inteligencia artificial (confianza: 0.87), DistilBERT'. The second conversation, titled 'Conversacion - MachineLearning - BERTIN', shows the same question and a response 'R: una rama de la inteligencia artificial que permite a los sistemas aprender y mejorar sin ser programados explícitamente (confianza: 0.71), BERTIN'. At the bottom, there's a text input field 'Tu pregunta' (Your question) and a 'Enviar' (Send) button.

Métricas

DistilBeERT nos arroja estas métricas:

Arquitectura: bert Capas (hidden layers): 12 Attention heads: 12 Hidden size: 768 Vocab size: 31002 Max position embeddings: 512 Parametros totales: 109,261,826 Parametros entrenables: 109,261,826.

Activacion: gelu Dropout: 0.1 Attention dropout: 0.1

BERTIN nos arroja estas métricas:

Arquitectura: roberta Capas (hidden layers): 12 Attention heads: 12 Hidden size: 768 Vocab size: 50265 Max position embeddings: 4098 Parametros totales: 126,809,090 Parametros entrenables: 126,809,090

Activacion: gelu Dropout: 0.1 Attention dropout: 0.1

Las métricas de los dos modelos utilizando el mismo contexto y las mismas preguntas base las podemos observar en el tab “Metricas”


Evaluacion contra test set			
Contexto usado: <i>El español es un idioma romance originario de la península ibérica. Es hablado por aproximadamente 600 millones de personas en el mundo, lo que lo convierte en la segunda lengua materna más hablada después del mandarín.</i>			
#	Pregunta	Respuesta esperada	
1	¿Cuántas personas hablan español aproximadamente?	600 millones	
2	¿De dónde es originario el español?	península ibérica	
3	¿Qué tipo de idioma es el español?	romance	
4	¿Cuál es la segunda lengua materna más hablada?	español	
Metrica	Descripcion	DistilBERT	BERTIN
EM	Exact Match (coincidencia exacta)	25.0%	75.0%
F1	F1 Score (precision/recall de tokens)	41.7%	75.0%
Precision	Tokens correctos predichos	37.5%	75.0%
Recall	Tokens de respuesta encontrados	50.0%	75.0%

BERTIN nos arroja mejores resultados ya que es un modelo más completo a diferencia de DistilBERT que es un destilado de BERT

Pipeline

El pipeline que sigue cada modelo para responder las preguntas lo podemos observar en el tab "Pipeline"

Seleccionamos el chat para obtener el contexto previamente cargado, seleccionamos el modelo al cual vamos a realizar la pregunta y del cual queremos ver el pipeline, ingresamos la pregunta y damos clic en ejecutar Pipeline, esto nos mostrara los pasos que sigue el modelo para responder la pregunta que ingresamos.



Paso 1 Tokenización

Tokeniza la pregunta y el contexto agregando tokens especiales [CLS] al inicio y [SEP] de clasificación y separación.

Después asigna un ID numérico a cada uno de los tokens según el vocabulario del modelo.



Paso 2 Inferencia

Los tokens numéricos pasan a tevez de capas de transformer, al final del proceso el modelo produce dos vectores de logits(valores numéricos crudos)

- Start Logits: Un valor por cada token que indica que tan probable es que la respuesta comience en esa posición.
- End Logits: Un valor por cada token que indica que tan probable es que la respuesta termine en esa posición.

En este caso la pregunta fue “¿Cuándo comenzó el grupo?” la respuesta es “2018” es un solo token y con el contexto de la inferencia podemos ver que start logits y end logits todos son negativos con excepción de 1 que es la posición inicio y fin del token de la respuesta.

Paso 2: Inferencia (forward pass)

Los tokens pasan por las capas del transformer. La salida son dos vectores de logits: uno para la posición de inicio y otro para la posición de fin de la respuesta.

• **Start logits shape:** [99] (1 logit por token)

• **End logits shape:** [99]

• **Start logits (raw):**

```
[-12.313371658325195, -12.451895713886152, -12.332743644714355, -12.333453178405762, -12.520586013793945, -12.662833081054688, -12.34521484375,
-12.18109138859375, -12.31555461883545, -12.919113159179688, -12.561264991760254, -13.229188919067383, -13.06747055053711, -13.078592300415039,
-13.258478164672852, -6.0733256340026855, -13.027743339538574, -13.006351470947266, -13.452309608459473, -13.095416069030762, -13.149484525756836,
-13.130247116088867, -13.0797119140625, -13.178016662597656, -12.785554885864258, -12.841535568237305, -12.984123229980469, -13.228855953979492,
-13.145622253417969, -13.394222259521484, -13.039375305175781, -13.162046432495117, -13.162375456134277, -13.077554702758789, -12.727428436279297,
-13.068562507629395, -12.523715019226074, -12.989297866821289, -13.205351829528809, -6.066249847412109, -12.68658447265625, -13.504531868351562,
-12.959871292114258, -12.65244197845459, -12.479312896728516, -13.078840255737305, -12.883418083190918, -13.610703468322754, -13.33761978149414,
-12.932357788085938, -12.777923583984375, -6.072205543518066, -13.016593933105469, -12.73085880279541, -12.46755599975586, -13.485462188720703,
-12.353819847106934, -11.967361450195312, -12.755029678344727, -12.902260780334473, -12.95197868347168, -13.055500030517578, -13.47689349731445,
-13.317333221435547, -11.28995418548584, -11.47161865234375, -3.3448967933654785, 3.996863683591919, -6.87711238861804, -12.689287185668945,
-13.337656021118164, -11.528815269470215, -12.559225082397461, -12.556621551513672, -6.008755207061768, -13.350997344970703, -13.114128112792969,
-13.298905372619629, -13.264650344848633, -13.637210845947266, -12.998108863830566, -12.251762390136719, -12.637140274047852, -10.539909362792969,
-13.371614456176758, -11.806353569030762, -12.925562858581543, -13.69624137878418, -13.564955711364746, -13.451643943786621, -13.358222961425781,
-13.5425386428833, -13.24863338470459, -12.959393501281738, -13.291488647460938, -13.585857391357422, -13.160469055175781, -13.691408157348633,
-13.04850959777832]
```

• **End logits (raw):**

```
[-11.921977996826172, -12.031408309936523, -11.870328320129395, -12.245707511901855, -12.401156425476074, -12.270220756530762, -12.869465637207031,
-12.320220947265625, -12.041261672973633, -12.320820808410645, -12.918962478637695, -11.933560371398926, -12.550618171691895, -12.664315223693848,
-12.432453155517578, -10.771196365356445, -12.664634704589844, -12.75174617767334, -12.070578575134277, -12.610174179077148, -12.650008057220459,
-12.629332542419434, -12.698256492614746, -12.512890815734863, -12.632838249206543, -12.76706600189209, -12.584831237792969, -12.50999927520752,
-12.647704124450684, -12.22482681274414, -12.714615821838379, -12.621169090270996, -12.566283226013184, -12.484225273132324, -11.13510799407959,
-12.27757453918457, -12.774965286254883, -12.545638084411621, -12.321240425109863, -10.784552574157715, -12.691596031188965, -11.381863670349121,
-11.446325302124023, -12.249552726745605, -11.852072715759277, -12.297529220581055, -12.627949714660645, -11.66588268737793, -12.248814582824707,
-12.730048179626465, -12.799382209777832, -10.789739608764648, -12.390839576721191, -12.886055946350098, -12.906523704528809, -11.79831314086914,
-12.831437110900879, -12.538204193115234, -12.489570617675781, -12.57412052154541, -12.720667839050293, -12.589555601379395, -11.23595905303955,
-11.257282257080078, -8.67002010345459, -12.39332103729248, -7.8831610679626465, -7.4264020919799805, 7.5010480800737305, -12.037867546081543,
-11.90465402868652, -13.17711353302002, -12.848809350891113, -12.87849235534668, -10.827521324157715, -12.316384206848145, -12.544114112854004,
-12.387511253356934, -12.374167442321777, -11.760058403015137, -12.25973129272461, -11.51419734954834, -12.336797714233398, -11.666033744812012,
-9.444618595703125, -12.25430679321209, -12.233522415161133, -11.628968238830566, -12.029502868652344, -12.154102325439453, -12.111321449279785,
-12.090826988220215, -12.287842750549316, -12.200318336486816, -12.331844329833984, -11.984724998474121, -12.186874389648438, -9.70710277557373,
-11.889378623962402]
```

Paso 3: Softmax y selección de posiciones

Una vez que se tienen los token se aplica la función softmax para convertirlos en 0 o 1, con esto se selecciona el token de inicio con la probabilidad más alta y el token de fin, si el token de fin aparece antes que el inicio la respuesta no es válida.

Paso 3: Softmax y seleccion de posiciones

Se aplica softmax para convertir logits en probabilidades, luego se elige el token con mayor probabilidad para inicio y fin. **Top-5 inicio:**

Token	Probabilidad
Ġ2018 (pos 67)	0.9992
desde (pos 66)	0.0006
Ġde (pos 74)	0.0000
Ġde (pos 39)	0.0000
Ġde (pos 51)	0.0000

Top-5 fin:

Token	Probabilidad
. (pos 68)	1.0000
Ġ2018 (pos 67)	0.0000
desde (pos 66)	0.0000
Ġ (pos 64)	0.0000
cientemente (pos 84)	0.0000

- **Inicio elegido:** posicion 67 (Ġ2018)
- **Fin elegido:** posicion 68 (.)

Paso 4: Decodificación

Una vez identificados los tokens de inicio y fin se extraen los tokens que están dentro de esas posiciones, se decodifican los tokens a texto utilizando el vocabulario del modelo, se eliminan los tokens especiales y espacios, se calcula la confianza de la respuesta multiplicando la probabilidad del token inicio por la probabilidad del token fin y el resultado es el texto plano con un valor de confianza que indica que tan seguro está el modelo de la respuesta que está proporcionando.

Paso 4: Decodificación de la respuesta

Se extraen los tokens desde la posición de inicio hasta la de fin, se decodifican a texto y se calcula la confianza.

- **Tokens respuesta (IDs):** [1824, 18]
- **Tokens respuesta (texto):** ['Ġ2018', '.']
- **Respuesta final:** 2018.
- **Confianza:** 0.9992 (99.92%)

Resumen

Pregunta: ¿Cuándo comenzó el grupo? **Respuesta:** 2018. **Confianza:** 99.92% **Modelo:** BERTIN

En este caso utilizamos el modelo BERTIN, DistilBERT funciona de la misma manera, cambian los tokens especiales de clasificación y separación, el tamaño de tokens con los que puede trabajar también es menor pero el pipeline sigue funcionando igual.

Conclusiones

El sistema nos muestra la viabilidad de implementar un chat utilizando modelos pre entrenados, comparando entre dos modelos BERTIN y DistilBERT observamos que existen diferencias de rendimiento y velocidad estos puntos los tenemos que tener en cuenta para el propósito de los desarrollos, con el pipeline y métricas que se implementaron nos damos cuenta los procesos que se desarrollan para poder contestar una pregunta del contexto dado.

El procesamiento de lenguaje natural es un tema muy interesante con muchas posibilidades de implementación en un entorno productivo.