

Procesamiento de Lenguaje Natural

Erick Chaparro Quintanar
Procesamiento de Lenguaje Natural
Maestría en Inteligencia Artificial
Profesor Gaddiel Desirena López

Objetivo

Construir un Chat capaz de responder preguntas basadas en documentos cargados por el usuario.

Integrar modelos pre entrenados como BERT o modelos para contextos grandes.

Modelos Implementados

BERTIN Optimizado para textos largos en español con capacidad de hasta 4096 tokens

DistilBERT es una versión comprimida de BERT que utiliza destilación de conocimiento para mayor velocidad

Pipeline

Tokenización: Convierte la pregunta y contexto en IDs numéricos con tokens especiales (Clasificación y separación)

Inferencia: Generación de Start Logits y End Logits para identificar la ubicación de la respuesta.

Softmax: Convierte los valores crudos en probabilidades para seleccionar inicio y fin más probable.

Decodificación: Transforma los tokens numéricos a texto plano.

Comparativa entre modelos

BERTIN más estable, mejores resultados globales, mayor capacidad de contexto.

DistilBERT mayor velocidad aunque con variaciones más marcadas en su porcentaje de confianza.

Conclusiones

Se demuestra la viabilidad de usar modelos pre entrenados, es necesario analizar las necesidades del desarrollo para elegir que modelo puede ser el ideal para el escenario que se necesite.